

SLHA v2

Vue d'ensemble du projet

Sub-Low Rank Hybrid Attention — compression de KV-cache pour LLM sur CPU

SLHA v2 compresse le KV-cache d'un LLM en tuiles de 128 octets calquées sur la ligne de cache (64 o), pour que l'inférence tienne dans L1/L2/L3 sur CPU plutôt qu'en VRAM. Chaque clé est décomposée en (1) une base latente de bas rang quantifiée INT4 et (2) un résidu 1-bit capturé par sign-LSH (Johnson-Lindenstrauss) et scoré par XOR+popcount. Un gestionnaire élastique (CCOS Soft-Paging) dégrade la fidélité HOT→WARM→COLD sous pression mémoire sans I/O ni allocation.

Faits clés mesurés (prototype scirust, §7)

Tuile	128 o exacts, 0 padding — latent 64 o + résidu 32 o + métadonnées 32 o	\$3.1
Score fusionné	$(q_coarse, dequant(latent)) + \lambda \cdot (d_s - 2 \cdot popcount(q_sign \oplus B))$	\$2.3
Latent	INT4 signé (zero-point), variantes MX groupé + NF4 — même tuile 128 o	\$5
Résidu	256 bits sign-LSH ; distance de Hamming = produit scalaire ± 1	\$2.2
SIMD x86	AVX2 $\times 11,5 \cdot$ AVX-512 $\times 14,1$ vs scalaire (Xeon)	\$7.4
SIMD ARM	NEON $\times 5,7$ (Jetson Thor AGX 128, lignes 64 o, sve2 détecté)	\$7.4
Bande passante	$2,5\times$ tokens/s vs clé bf16 (2 $\times$ moins d'octets/token)	\$7.5
Fidélité sortie	$\cos(\text{softmax}\cdot V)$ 0,95–0,997 vs attention FP — le softmax absorbe	\$7.6
Soft-Paging	pager $\frac{1}{2}$ tuiles HOT→WARM : sortie à $\cos$ 0,9995 (quasi sans perte)	\$4
Levier réel #1	projection bas-rang apprise (SGD task-aware) : WARM 0,16→0,86	\$7.7
Faux levier	largeur de bits : INT8 = INT4 au coarse — le goulot est la projection	\$7.8
λ calibrée	forme $\propto \sigma_E$ validée ; constante corrigée $\times 4,2 \rightarrow C_emp \approx 0,33$	\$7.9


Architecture du crate scirust (workspace Cargo)

attention/slha_v2.rs	Tuile 128 o, codecs INT4/MX/NF4, kernels AVX2/AVX-512/NEON, popcount VPOPCNTDQ
ccos.rs	ElasticKvCache : arène contiguë, HOT/WARM/COLD, enforce_budget, free-list
learned.rs	PCA (jacobi_eigh) + projection task-aware SGD, whitening, encode/decode
metrics.rs · linalg.rs	$\cos$ /spearman/softmax, eigendecomposition, PRNG gaussien
audit.rs + bin/slha_audit.rs	Auto-audit runtime : layout, équivalence SIMD, fidélité, budget, déterminisme
slha-mcp/	Serveur MCP stdio zero-dep : 5 outils (audit/explain/compress/score/benchmark)
examples/ · scripts/	measure, calibrate_lambda, ccos_softpaging, platform_report, stress_test

SLHA v2 Schéma de principe

Flux de données : encodage clé, chemin requête, score fusionné, tuile, Soft-Paging

① Encodage d'une clé K_j (par tête n)



④ Tuile SLHA v2 — 128 octets = 2 lignes de cache (align 64/128)


Latent INT4 64 o	Résidu 1-bit 32 o	Métadonnées 32 o
d_c=128 $\rightarrow$ 64 o (1 ligne pleine)	256 bits = 4x64 (AVX-512 / NEON)	scale, λ , σ_E , token, pos, head, flags, group_scales
ligne 0 (64 o)	ligne 1 (64 o)	

⑤ CCOS Soft-Paging — élasticité de fidélité sous budget mémoire



SLHA v2 Logigramme d'exécution

Boucle de génération : encodage, gestion budget, scoring, dispatch SIMD



Audit & agent : slha-audit (layout, équivalence SIMD, fidélité, budget, déterminisme → rapport JSON/MD) · slha-mcp expose audit/explain/compress/score/benchmark aux LLM-agents.

SLHA v2 Plan d'amélioration

Axes prioritisés · grounding littérature · roadmap

Le projet a validé la *mécanique* (51 tests, équivalences SIMD, Soft-Paging quasi sans perte, sortie d'attention cos 0,95-0,997) et identifié, par la mesure, ses *vrais* leviers : la projection bas-rang (A1) et le résidu 1-bit (A2/A3) — la quantification du latent n'est pas le goulot. Le plan ci-dessous priorise donc la fidélité et la politique de cache, avant l'optimisation matérielle, et ancre chaque axe dans la littérature périphérique 2022-2026.

Tableau des axes (priorité / effort)

ID	Axe	Priorité	Effort	Gain attendu
A1	Projection bas-rang sur clés PRE-RoPE	Critique	Moyen	Lève le plafond WARM à la source — explique le goulot « projection » du §7.8.
A2	Blanchiment par incohérence Hadamard (QuIP# / Palu)	Critique	Moyen	Meilleure résolution du résidu + latent ; tombe pile sur le goulot mesuré.
A3	Projection entraînée (Cayley orthogonale) + Matryoshka	Critique	Élevé	Lève le plafond WARM (0,16→0,86 déjà montré) sur vrai modèle ; multi-rang natif.
A4	Résidu multi-bit + LSH multi-round (Soft-Paging	Haute	Moyen	Fidélité graduée + meilleur HOT à rho élevé ; Soft-Paging plus fin.
A5	Éviction informée (heavy-hitters / sinks / observation window)	Haute	Faible	Moins de dérive sous forte pression ; cohérent avec la pratique LLM 2024-26.
A6	Quantification asymétrique K/V (per-channel K, per-token V)	Haute	Moyen	Réduit l'erreur latent sur vrais modèles ; GEAR = analogie externe du système complet.
A7	Validation matérielle réelle (perf + perplexité)	Haute	Moyen	Transforme les hypothèses §6 en résultats ; crédibilité du papier.
A8	Pagination KV par blocs (PagedAttention) + prefetch	Moyenne	Moyen	Multi-requête, partage de préfixe, fragmentation contrôlée — usage serveur.
A9	Top-k approx + re-rank two-pass	Moyenne	Moyen	Débit long-contexte ; cohérent avec la sémantique HOT/WARM.
A10	LSH appris / anisotrope + normalisation shared-QK	Moyenne	Moyen	Meilleur Spearman du cœur binaire (0,67 → ?) sans plus de bits.
A11	Chemin SVE2 / scalable vector pour ARM	Moyenne	Élevé	Gain ARM supplémentaire (largeur de vecteur adaptative) ; route serveur Neoverse.
A12	Kernel NF4 LUT + format MX (finition)	Basse	Faible	Accélère le chemin NF4 + robustesse des group scales ; gain fidélité faible.

Lecture : Critique = lève le plafond de fidélité ; Haute = gain mesurable direct ; Moyenne/Basse = optimisation ou validation.

SLHA v2 Plan d'amélioration — détail (1)

Problème · Levier · Grounding littérature

A1 — Projection bas-rang sur clés PRE-RoPE

Critique · effort Moyen

Problème Le plafond de fidélité du coarse tient à la projection (§7.8). Or RoPE *mélange* les canaux et crée des outliers : une projection post-RoPE est structurellement sous-optimale.

Levier Appliquer W_{down} sur les clés PRE-RoPE (avant rotation), reconstruire puis post-rotater. ShadowKV montre que les clés pre-RoPE sont *bien* plus low-rank que post-RoPE : c'est probablement le plus gros gain de fidélité latent disponible, et il explique le goulot mesuré.

Littérature ShadowKV (arXiv 2410.21465), KVQuant pre-RoPE (2401.18079).

Gain attendu Lève le plafond WARM à la source — explique le goulot « projection » du §7.8.

A2 — Blanchiment par incohérence Hadamard (QuIP# / Palu)

Critique · effort Moyen

Problème Le résidu 1-bit perd de la résolution sur directions quasi-orthogonales (Spearman 0,67, §7.1) ; l'énergie résiduelle est concentrée sur quelques canaux (outliers).

Levier Transformée de Hadamard aléatoire ($RHT = \text{Hadamard} \times \text{diagonale } \pm 1$) appliquée à E et Q avant le sign-LSH : « incoherence processing » qui uniformise l'énergie, chaque bit capte autant d'info, outliers supprimés. FWHT en $O(n \log n)$, entrées ± 1 (pas de FP mul). Appliquer aussi au latent.

Littérature QuIP# (2402.04396), Palu Walsh-Hadamard fused (2407.21118), NSNQuant (2505.18231).

Gain attendu Meilleure résolution du résidu + latent ; tombe pile sur le goulot mesuré.

A3 — Projection entraînée (Cayley orthogonale) + Matryoshka Critique · effort Élevé

Problème La SGD task-aware (§7.7) n'est validée que sur données synthétiques, P seule, sans vrai modèle. MatryoshkaKV confirme que PCA est sous-optimal pour les LLM (non-linéarité).

Levier Fine-tuner W_{down}/W_{up} conjointement avec un vrai LLM, paramétrisation Cayley (orthogonale : produits scalaires préservés par construction), init PCA. Entraînement Matryoshka (rangs aléatoires) : un seul modèle sert toute l'échelle HOT/WARM. Fusionner W_{up} dans la projection de sortie (Palu) pour une reconstruction zéro-coût runtime.

Littérature MatryoshkaKV (2410.14731), Palu (2407.21118), StiefAttention (2601.21686), Linformer (2006.04768).

Gain attendu Lève le plafond WARM (0,16→0,86 déjà montré) sur vrai modèle ; multi-rang natif.

A4 — Résidu multi-bit + LSH multi-round (Soft-Paging gradué) Haute · effort Moyen

Problème 256 bits sign-LSH = 1 bit/hyperplan : modeste. Le résidu est paginé binairement (WARM on/off), pas gradué. Reformer montre qu'un seul bitmap a un fort taux de faux-négatifs.

Levier (a) Multi-round LSH : 2-3 bitmaps indépendants, vote majoritaire ; (b) résidu additif/RVQ : un niveau ± 1 + un niveau fin sur le sous-espace à forte σ_E . Soft-Paging devient gradué (HOT2→HOT1→WARM). Codebook partagé pré-calculé (NSNQuant) pour économiser la mémoire résiduelle. Normalisation shared-QK avant signing (cohérence hash query↔key).

Littérature Reformer LSH (2001.04451), RBE/BEBR (1802.06466, 2302.08714), QINCo (ICML 2024), NSNQuant (2505.18231).

Gain attendu Fidélité graduée + meilleur HOT à rho élevé ; Soft-Paging plus fin.

A5 — Éviction informée (heavy-hitters / sinks / observation window)

Haute · effort

Faible

Problème

L'éviction COLD est purement causale (plus ancien d'abord). Or l'attention a des heavy-hitters et des sinks (premiers tokens) qu'évincer détruit la qualité. σ_E seul ignore l'importance réelle.

Levier

Politique d'importance : score cumulé par token (H2O), préservation des attention sinks (StreamingLLM — pinner les premiers tokens en HOT), fenêtre d'observation pré-décodage (SnapKV) pour un budget par tête, pyramide par couche (PyramidKV : +de KV en couches basses). σ_E devient un signal complémentaire, pas seul critère. Profiling par tête une fois (FastGen) $\Rightarrow \lambda$ et budget par tête.

Littérature

H2O (2306.14048), StreamingLLM (2309.17453), SnapKV (2404.14469), PyramidKV (2406.02069), FastGen (2310.01801).

Gain attendu

Moins de dérive sous forte pression ; cohérent avec la pratique LLM 2024-26.

A6 — Quantification asymétrique K/V (per-channel K, per-token V)

Haute · effort

Moyen

Problème

BF4/MX réduisent l'erreur de reconstruction mais le gain end-to-end est marginal (\$7.8). KIVI montre que K et V ont des statistiques *différentes* : K a des outliers par canal, V non.

Levier

Traitement asymétrique : latent h_K quantifié par canal, h_V par token. Fenêtre résiduelle FP glissante (KIVI) comme baseline à comparer au bitmap 1-bit. Extraction des canaux outliers en FP/sparse (Atom, GEAR) si leur nombre tient dans le budget tuile. Réordonnancement de canaux pour isoler les outliers (Atom) — compatible avec le tuilage cache.

Littérature

KIVI (2402.02750), Atom (2310.19102), GEAR (2403.05527), QAQ (2403.04643), AWQ.

Gain attendu

Réduit l'erreur latent sur vrais modèles ; GEAR = analogie externe du système complet.

SLHA v2

Plan d'amélioration — détail (4)

Problème · Levier · Grounding littérature

A7 — Validation matérielle réelle (perf + perplexité)

Haute · effortMoyen

Problème

Compteurs de cache (§6.1) et perplexité d'un vrai modèle (§6.3) restent non mesurés (sandbox). Les ratios SIMD sont indicatifs (banc partagé).

Levier

Runner perf stat (L1/L2/LLC misses) sous Debian 13 ; intégrer à un vrai décodeur (greffon llama.cpp/vLLM) pour TTFT, débit bout-en-bout et Δperplexité HOT/WARM/COLD. slha-audit peut collecter ces compteurs en CI sur metal. Sans cela, les cibles §6 restent des hypothèses.

Littérature

Pancs vLLM, perf_event, KV-Runahead.

Gain attendu

Transforme les hypothèses §6 en résultats ; crédibilité du papier.

A8 — Pagination KV par blocs (PagedAttention) + prefetch scheduler

Moyenne · effortMoyen

Problème

L'arène contiguë de ccos.rs recycle des slots mais ne pagine pas par blocs fixes ; pas de partage de KV entre requêtes (prefix sharing) ni de fragmentation contrôlée.

Levier

Tuile 128 o = page naturelle. Tables de pages + mapping logique→physique (relocation HOT→WARM sans copier le latent), copy-on-write pour prefix sharing multi-requête, prefetch scheduler-aware (réchauffer les bitmaps droppés depuis la file de jobs). CCOS devient un paged KV manager au-dessus des tuiles.

Littérature

LM/PagedAttention (2309.06180), AttentionStore (2403.19708), ChunkAttention (2402.15220).

Gain attendu

Multi-requête, partage de préfixe, fragmentation contrôlée — usage serveur.

A9 — Top-k approx + re-rank two-pass

Moyenne · effort Moyen

Problème On score *toutes* les tuiles live. A très long contexte, même 128 o/token coûte.

Levier Passe 1 coarse-only (résidu droppé) pour filtrer un top-k candidat, passe 2 HOT (résidu) pour reranker.
Soft-Paging = filtre naturel : WARM = passe 1, HOT = passe 2. Réduit le travail de popcount au top-k.
ChunkAttention donne le pattern de merge softmax en ligne pour le batching.

Littérature Reformer LSH filtering (2001.04451), ScaNN anisotropic + re-rank, ChunkAttention (2402.15220).

Gain attendu Débit long-contexte ; cohérent avec la sémantique HOT/WARM.

A10 — LSH appris / anisotrope + normalisation shared-QK

Moyenne · effort Moyen

Problème Z est une projection JL Gaussienne *fixe* — sous-optimale pour la distribution réelle des résidus. Reformer normalise Q/K partagés avant le hash pour la cohérence.

Levier Apprendre Z (ou un codebook binaire) pour maximiser corrélation $\text{sign}(Z \cdot E) \leftrightarrow \cos(E, \text{requête})$, SGD ou PCA signée, conjoint avec A3. LSH anisotrope (préférence aux voisins de forte similarité, pas cosinus uniforme).
Normaliser Q/K avant signing (cohérence query↔key bitmap).

Littérature ScaNN (anisotropic quantization), Reformer shared-QK (2001.04451), BOLT, NSNQuant (2505.18231).

Gain attendu Meilleur Spearman du cœur binaire (0,67 → ?) sans plus de bits.

A11 — Chemin SVE2 / scalable vector pour ARM Moyenne · effort Élevé

Problème SVE2 est présent sur la cible Jetson Thor mais non exploité : intrinsèques nightly-only en Rust, chemin NEON+cnt livré seulement.

Levier Ajouter un chemin SVE2 via asm! manuel (vectorisation scalable) validé *sur appareil* (test d'équivalence bit-à-bit comme les autres chemins), repli NEON. Surveiller la stabilisation des intrinsèques core::arch::aarch64.

Littérature Spécification ARM SVE2 ; std::simd Rust.

Gain attendu Gain ARM supplémentaire (largeur de vecteur adaptive) ; route serveur Neoverse.

A12 — Kernel NF4 LUT + format MX (finition) Basse · effort Faible

Problème La déquant NF4 coûte 21-40 % de la latence (LUT 16 niveaux). Les MX group scales peuvent déborder. Gain end-to-end NF4 marginal (\$7.8) : à ne prioriser qu'après A1-A3.

Levier LUT NF4 en mémoire partagée (Fast NF4 kernel, ~2x). Group scales E8M0 (OCP MX) ou FP8 partagé asymétrique (AMXFP4) ; Overflow-Aware Scaling (OAS) pour le débordement logiciel. Décision pilotée par la mesure, comme les codecs existants.

Littérature Fast NF4 dequant (2604.02556), AMXFP4 (2411.09909), OAS+MBS (2603.08713), OCP MX (ARITH 2025).

Gain attendu Accélère le chemin NF4 + robustesse des group scales ; gain fidélité faible.

SLHA v2 Roadmap & honnêteté

Phases · dépendances · limites assumées

Phases proposées (12-18 mois)

Phase 1 — Fidélité (A1, A2, A3)

Entraînement conjoint de la projection + incohérence Hadamard + résidu multi-bit. Objectif : lever le plafond WARM et graduer le Soft-Paging. Livrable : projection entraînée sur un petit LLM, banc de fidélité score/sortie/perplexité.

Phase 2 — Politique de cache (A4, A5, A9)

Eviction informée (heavy-hitters/sinks) + pagination par blocs (PagedAttention) + two-pass top-k. Objectif : long contexte et multi-requête serveur avec moins de dérive. Livrable : ElasticKvCache v2 sur tuiles-pages.

Phase 3 — Validation matérielle (A8, A6)

Intégration greffon llama.cpp/vLLM, perf stat (cache misses), perplexité réelle, chemin SVE2 validé sur appareil. Objectif : transformer les hypothèses §6 en résultats mesurés.

Phase 4 — Finition (A7, A10)

Quantification asymétrique/outliers et LSH appris — uniquement après que A1-A3 ont montré leur plafond. Décisions pilotées par la mesure.

Limites assumées & principes à conserver

- Les valeurs §6 ($\geq 85\%$ cache misses, $3,5\text{-}5\times$, $\Delta P < 0,04$) restent des hypothèses tant que A8 n'est pas fait.
- Les ratios SIMD sont indicatifs (banc partagé) — mesurer les vôtres ; ne pas les présenter comme résultats.
- Ne pas réintroduire un faux levier (largeur de bits) : la projection est le goulot, mesuré (§7.8).
- Tuile 128 o et invariant zéro-padding sont l'actif matériel — toute évolution doit préserver l'alignement cache.
- Toute technique empruntée (Hadamard, RVQ, heavy-hitters) doit être validée par test d'équivalence + banc, comme les chemins SIMD existants — pas ajoutée sur foi de la littérature.